




## Ridge Regression method


이해를 돕기 위해 feature가 2개인 경우를 생각해 보자.





## Ridge Regression method


여기서 고를 수 있는  $(\beta_1, \beta_2)$ 의 조합은 무수히 많다.





## Ridge Regression method


어떤 계수가 '좋은' 계수인지 조건이 필요했고,  
평균제곱오차(MSE)를 기준으로 사용해 계수를 추정하였다(최소제곱법).  
그 계수인  $\beta_1$ 과  $\beta_2$ 를 점  $(\beta_1, \beta_2)$ 인  $\hat{\beta}$ 이라고 하자.





## Ridge Regression method

$\hat{\beta}$ 는 MSE가 가장 작은 점이고,  $(\beta_1, \beta_2)$ 의 조합에 따라 MSE가 달라진다.  
 $\hat{\beta}$ 에서 멀어질수록 MSE가 커진다.








## Ridge Regression method

그런데 알려진 사실에 따르면, MSE가 커지는 데는 어떤 '규칙'이 있다.  
MSE가 같은 점을 이어 보면 타원 모양이 된다.

$$\begin{aligned}
 &MSE(\hat{\beta}) \\
 &< MSE(\tilde{\beta}_3) \\
 &< MSE(\tilde{\beta}_1) = MSE(\tilde{\beta}_2)
 \end{aligned}$$








## Ridge Regression method


한편 회귀계수의 크기가 너무 크면 과적합(overfitting)의 가능성이 있다.





## Ridge Regression method

Ridge regression: 회귀계수의 범위를 원 안으로 제한한다.  
단, 평가 기준은 똑같이 MSE를 사용








## Ridge Regression method

회귀계수의 범위를 원 안으로 제한


= 회귀계수의 L2 크기(=원점과의 L2 거리)를 제한





## Ridge Regression method


원 안의 회귀계수중 MSE가 제일 작은 점은  $\tilde{\beta}_1$ 이다.





## Ridge Regression method


원의 반지름이 커지면 선택되는 회귀계수도 달라진다.  
이 경우는  $\tilde{\beta}_3$ 를 선택한다.






## Ridge Regression method

원이 최소제곱법으로 추정한  $\hat{\beta}$ 을 포함할 정도로 커지면 항상  $\hat{\beta}$ 을 선택한다.  
이때부터는 원이 커져도 의미가 없다.





## Ridge Regression method 요약



$t = 0$ 이면 회귀계수는 0  
 $t = \infty$ 이면 회귀계수는  $\hat{\beta}^{LS}$


타원과 원의 교점이  $\hat{\beta}^{Ridge}$

위 과정을 통해 회귀계수의  
**크기가 작아진다.**



## LASSO Regression method


LASSO regression: 회귀계수의 범위를 마름모 안으로 제한한다.  
단, 평가 기준은 똑같이 MSE를 사용






## LASSO Regression method

LASSO regression: 회귀계수의 범위를 마름모 안으로 제한한다.  
단, 평가 기준은 똑같이 MSE를 사용





## LASSO Regression method 요약



$t = 0$ 이면 회귀계수는 0

$t = \infty$ 이면 회귀계수는  $\hat{\beta}^{LS}$

마름모와 원의 교점이  $\hat{\beta}^{Lasso}$



위 과정을 통해

회귀계수 **대부분이 0**이 된다  
(sparsity).





## Ridge vs LASSO





(참고) LASSO Regression(L1 Regularization)

회귀계수 대부분을 0으로 보내기 때문에 변수 선택의 역할이 가능하다.

Ordinary Least Square method:  $\min \sum_{i=1}^n (y_i - \hat{y}_i)^2$

$$\Leftrightarrow \min (y - X\beta)^T (y - X\beta)$$

LASSO Regression method:  $\min \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \text{s.t.} \quad \sum_{j=1}^p |\beta_j| \leq t$

$$\Leftrightarrow \min (y - X\beta)^T (y - X\beta) + \lambda ||\beta||_1$$

MSE뿐만 아니라 회귀계수의 (L1)크기까지 최소화  
 $\lambda$ 가 커진다 -> 벌점이 커진다 -> 더 작은  $\beta$ 를 사용해야 한다.



## (참고) Ridge Regression(L2 Regularization)

회귀계수를 추정할 때 값이 커지지 않도록 **벌점(L2 penalty)**을 부여한다.

Ordinary Least Square method:  $\min \sum_{i=1}^n (y_i - \hat{y}_i)^2$


$$\Leftrightarrow \min (y - X\beta)^T (y - X\beta)$$

Ridge Regression method:  $\min \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \text{s.t.} \quad \sum_{j=1}^p (\beta_j)^2 \leq t^2$

$$\Leftrightarrow \min (y - X\beta)^T (y - X\beta) + \lambda ||\beta||^2$$

MSE뿐만 아니라 회귀계수의 (L2)크기까지 최소화  
 $\lambda$ 가 커진다 -> 벌점이 커진다 -> 더 작은  $\beta$ 를 사용해야 한다.

- 📖 Elasticnet: LASSO + Ridge (hybrid method)  
$$\min (y - X\beta)^T(y - X\beta) + \lambda_2 \|\beta\|_2^2 + \lambda_1 \|\beta\|_1$$
  
 $\lambda_2 = 0$  이면 LASSO regression,  $\lambda_1 = 0$  이면 Ridge regression  
여기서  $\lambda_1, \lambda_2$  는 모두 사전에 지정해줘야 하는 hyperparameter이다.





## (참고) 데이터 표준화

LASSO 회귀분석은 회귀계수의 크기(norm)에 제약조건을 걸어준다.

그런데 회귀계수  $\beta_1, \beta_2, \dots, \beta_p$  는 각각 특징  $X_1, X_2, \dots, X_p$  와 관련되어 있다.

따라서 회귀계수는 각 특징의 단위(scale)에 의존하고,  
표준화를 하지 않고 분석을 시행하면 문제가 생길 수 있다.